



透明物体 Baseline 复现进度

Baseline → DepthHypothesisPack v1 → 下一阶段 gate

MDE Research

2026.09.01





路线图：先把比较尺子做对，再验证 Idea

1 全景

原生 benchmark

- ✓ Depth4ToM Base / Booster
- ✓ DFNet / TransCG full
- ✓ ReMake / TransCG full

论文或官方协议下的模型分数

多层主基线

- ✓ LayeredDepth val (300)
- ✓ SeeGroup val / teacher 审计
- ✓ 双向 bridge diagnostics

单层与多层放进同一评测

我们的模型与下游

- ✓ DHP ResNet / DINOv2-S
- ✓ 尺度锚定诊断
- ✓ ShellBench / frozen planner

同一协议定位真实失败模式

原生复现 官方数据 / checkpoint / evaluator

统一 benchmark 我们的共同协议

诊断 / oracle 隔离表示上限

当前结论：多层表示信号成立，但 DHP 主性能 gate 未通过；下一步应解决域对齐。

数据源：baseline_results_2026-08-30.json；depth_hypothesis_pack_v1_results_2026-08-31.json。



Step 1 | 比较尺子可信吗？原生结果已对齐

2 原生 benchmark

Depth4ToM code path ·Booster (228)

Model	本地 ToM RMSE	论文	状态
MiDaS v2.1 Base	140.40 mm	140.31	✓
DPT-Large Base	136.28 mm	136.28	✓

边界：这里只能称为 **Base**。Depth4ToM FT checkpoint 未公开，不能宣称已复现 FT。

TransCG official test (52 scenes / 23,524)

Masked metric	本地 ReMake	论文 Table I
RMSE ↓	0.010854 m	0.011 m
REL ↓	0.016906	0.017
MAE ↓	0.007532 m	0.008 m
$\delta_{1.05}$ ↑	93.9086%	93.91%

✓ **ReMake**：全部 masked 指标在论文报告精度内一致。

△ **DFNet current release**：masked RMSE 0.032787 m；全量完成，但 checkpoint 与论文旧版不同。


TransCG 数据已完整下载并审计：13 个分卷、23,524 个样本、CRC / 结构检查通过。

数据源：Depth4ToM official evaluator；TransCG native evaluators；ReMake Global Loss。




Step 2 | 为什么需要多层？single-depth 丢失界面

3 核心 gap



一条相机射线可穿过多个介质界面；只保留最近表面，会直接丢掉内壁与后壁。



+37.572 pp
SeeGroup vs 最强 single-depth 的 layer_all gap

数据源：LayeredDepth validation，300 images；195,800 mixed-layer quadruplets。

mixed-layer : 0% vs 66.610%
DPT / MiDaS 无法回答跨层 quadruplet



Step 3 | 能直接拼接吗？multi-layer 尚未米制对齐

3 核心 gap

SeeGroup closest layer $\rightarrow$ Booster ToM (228)

直接把 raw head 当米制

3372.31

mm ToM RMSE

AbsRel 3.7827 $\cdot \delta_{1.05}$ 0.00018%



Depth4ToM affine alignment 后

65.54

mm ToM RMSE

AbsRel 0.0642 $\cdot \delta_{1.05}$ 44.24%

多层相对结构



域对齐 + 多界面监督



米制 single-depth readout

51.46 $\times$ 的差异说明：结构信息是可用的，但输出空间没有对齐。

这不是 SeeGroup 的原生失败分数，而是跨协议 calibration stress test。

数据源：SeeGroup released checkpoint；Booster ToM protocol。



Step 4 | 我们的尝试：固定多层 Head，受控筛选 encoder

4 DepthHypothesisPack

RGB $\rightarrow$ encoder $\rightarrow d_1 < d_2 < d_3 < d_4$ + monotone presence + uncertainty
同一 K=4 head、loss、synthetic split、校准与 evaluator

1k frozen pilot：谁值得扩大？

Encoder	Depth MAE $\downarrow$	Front $\downarrow$	Pres. F1 $\uparrow$
DINOv2-S	0.522	0.465	0.9005
Depth Anything V2-S	0.537	0.477	0.8755

✓ DINO 扩大到 14,800 张； △ DA-V2 按 pilot gate 停止。

真实 LayeredDepth：结构是否增强？

Method	First	All	Mixed
MiDaS Base	66.17	34.84	0.00
DHP ResNet	41.63	32.04	20.45
DHP DINOv2-S	39.59	32.91	25.12
SeeGroup	78.37	72.41	66.61

Mixed quad：20.45% $\rightarrow$ 25.12% 但 TablewareNet interface F1：0.422%
更强 encoder 提升跨层排序，却没有解决 synthetic $\rightarrow$ operation domain 的米制迁移

数据源：LayeredDepth-Syn train only；ResNet formal fine-tuned，DINO / DA frozen；真实数据均为 evaluation-only。



Step 5 | 失败在哪里？主要是域与米制界面对齐

5 统一 ShellBench

100 scenes / 700 RGB views · 98 hollow-scored scenes · 259 objects · 1,813 event maps · 139.2M rays

Readout	性质	Interface F1 ↑	Transition F1 ↑
T ² SQNet + GT mask	multi-layer oracle input	79.23%	73.59%
T ² SQNet + RGB / LangSAM	multi-layer end-to-end	74.27%	69.14%
Perfect rendered front	single-depth upper bound	43.104%	—
DHP ResNet formal	synthetic → OOD	0.924%	—
DHP DINOv2-S	synthetic → OOD	0.422%	—
DHP DINO + bg affine*	scale oracle diagnostic	1.693%	—

不是一个全局 scale
即使用 test GT 求最优 affine，front MAE 仍有 88 mm

尺度修正有用，但远远不够
bg affine：0.422% → 1.693%，仍远低于 43.104%

结论：瓶颈是域内米制 / interface 监督，而不是继续堆通用 encoder。

数据源：DHP 使用 GT identity / association / rendered-front visibility adapter；* 另用 test bg depth + GT union mask。



Step 6 | 多层预测改善动作了吗？还没有过 gate

5 统一 ShellBench

同一批 244 matched objects / 7,983 frozen candidates；数字均为 safe / collision / reject

输入几何	Front optimistic	Front conservative	K-event parity
DHP ResNet formal	223 / 21 / 0	197 / 5 / 42	198 / 5 / 41
DHP DINO raw	226 / 18 / 0	228 / 5 / 11	229 / 5 / 10
DINO + bg affine*	227 / 16 / 1	206 / 2 / 36	211 / 2 / 31
GT shell oracle	224 / 20 / 0	240 / 0 / 4	244 / 0 / 0

表示上限成立

GT full events : 244 safe / 0 collision / 0 reject

当前模型质量不足

affine 将 collision 5 → 2，却使 safe 229 → 211

所以现在训练 planner head，只会让下游学习上游的几何错误。

数据源：* 尺度 oracle；offline target-shell collision gate，不是机器人 task success。



Decision | 不再堆 baseline / encoder，转向域对齐训练

6 结论

Idea 有表示层证据；当前失败点已定位为 synthetic $\rightarrow$ operation domain 对齐。

我们现在确定知道什么

- ✓ Baseline 与统一 benchmark 已冻结
- ✓ K=4 mixed signal : 20.45% $\rightarrow$ 25.12%
- △ DINO direct interface F1 仅 0.422%
- △ Scale oracle 也只有 1.693%
- ✓ SeeGroup raw teacher / 简单 scale 已审计
- ✓ 46 unit + 2 integration checks 全通过

暂不做：更多重型复现、扩大 test benchmark、transition / learned planner

下一项唯一有信息量的实验

- 1 TablewareNet training 3,000 scenes : 导出 physical-shell GT
- 2 小 pilot : synthetic ordering + 域内 metric / interface
- 3 独立 validation 100 scenes : 选模型 / 校准 / 过 gate
- 4 配置冻结后，只跑一次现有 test 100 scenes
- 5 过 gate 后，再加 transition / planner head

主表继续分开：TransCG metric depth | LayeredDepth multi-layer | ShellBench interfaces / collision；现有 test 保持冻结。

数据源：DepthHypothesisPack v1 强编码器与尺度诊断（2026-08-31）。